

أولاً: مميزات SMOTE

SMOTE يقوم بإنشاء عينات اصطناعية للفئة الأقلية باستخدام الاستيفاء بين عينات الأقلية وجيرانها الأقرب، بدلاً من مجرد تكرار العينات الموجودة.

أهم مميزات:

1. معالجة Class Imbalance

• يزيد تمثيل الفئة الأقلية ويجعل عملية التدريب أكثر توازناً.

2. إنشاء عينات اصطناعية بدل تكرار العينات

• يقلل مشكلة الاعتماد على النسخ المتطابقة التي قد تزيد خطر حفظ النموذج لعينات التدريب.

3. تحسين قدرة النموذج على تعلم الفئة الأقلية

• وجود أمثلة أكثر للفئة الأقلية قد يساعد في تحسين مقاييس مثل F1 و Recall، حسب طبيعة البيانات والنموذج.

4. بسيط وسهل التطبيق

• آليته أبسط من العديد من متغيرات SMOTE، ولذلك يمثل Baseline مناسباً عند دراسة تقنيات معالجة عدم التوازن.

5. لا يعتمد على تكرار الحالات الأقلية حرفياً

• العينات الجديدة يتم توليدها من العلاقات المحلية بين عينات الأقلية.

6. قابل للاستخدام مع نماذج تصنيف مختلفة

• يمكن دمجه مع خوارزميات متعددة، وخصوصاً داخل Pipeline لمنع Data Leakage.

7. أثبت فائده في عدد من التطبيقات

• توجد دراسات تجريبية تشير إلى أن استخدام SMOTE يمكن أن يحسن التعرف على الفئة الأقلية، لكن التحسن يعتمد على طبيعة Dataset.

ثانيًا: عيوب Borderline-SMOTE

الفكرة الأساسية في Borderline-SMOTE هي أنه لا يولد العينات بشكل عام مثل SMOTE؛ بل يركز على Minority Samples القريبة من حدود الفصل بين الفئات. وهذا التركيز يعطيه مزايا في بعض الحالات، لكنه يخلق عيوبًا أيضًا:

1. حساس جدًا لتحديد الـ Borderline

يجب عليه أولاً تحديد العينات:

Safe
Danger / Borderline
Noise

إذا تم تصنيف العينة بشكل خاطئ، فإن عملية التوليد اللاحقة قد تكون غير مناسبة. وقد أشارت أبحاث حديثة إلى أن عدم دقة تحديد Borderline Samples يؤدي إلى سوء توليد العينات الاصطناعية.

2. قد يضخم الضوضاء الموجودة على الحدود

إذا كانت منطقة الـ Decision Boundary تحتوي على:

Noise•
Outliers•
Mislabelled Samples•

فإن التركيز على هذه المنطقة قد يؤدي إلى إنشاء عينات إضافية حول منطقة غير موثوقة، وبالتالي قد يضر التعميم.

وهذا مهم لأن الحدود الصعبة ليست دائمًا حدودًا حقيقية؛ قد تكون أحيانًا نتيجة ضوضاء في البيانات.

3. قد يزيد تداخل الفئات

إذا كانت عينات Minority الموجودة على الحدود قريبة جدًا من Majority، فإن إنشاء عينات جديدة حولها قد يزيد:

Class Overlap

وبالتالي يصبح الفصل بين الفئتين أصعب بدلاً من تحسينه.

4. يهمل جزءًا من Minority Class

SMOTE التقليدي يتعامل مع عينات الأقلية على نطاق أوسع، بينما Borderline-SMOTE يركز على العينات الحدودية.

لذلك إذا كانت العينات الحدودية قليلة، فقد لا يحصل باقي توزيع الـ Minority على تمثيل كافٍ.

5. حساس للـ k-neighbors

تحديد:

k_neighbors
m_neighbors

يؤثر في تحديد ما إذا كانت العينة:

Safe
Danger
Noise

وبالتالي اختيار قيم غير مناسبة يمكن أن يؤثر مباشرة على جودة العينات الاصطناعية.

6. قد لا يعطي تحسنًا دائمًا

ليس صحيحًا أن:

Borderline-SMOTE أفضل دائمًا من SMOTE.

المقارنات التجريبية أظهرت أن أداء Borderline-SMOTE يعتمد على Dataset والخوارزمية؛ ففي بعض الحالات لم يحسن الأداء الكلي، وإن كان قد يفيد نماذج معينة أو حالات معينة.

7. أقل بساطة من SMOTE

لأنه يضيف مرحلة تحديد الحالات الحدودية قبل عملية التوليد، وبالتالي يصبح أكثر تعقيداً من SMOTE التقليدي.